
Tarea de PCA y Clustering

 **nticmaster**



U N I V E R S I D A D
COMPLUTENSE
M A D R I D

Carlos San Román Cazorla

Universidad Complutense de Madrid

Máster de IA, Big Data y Data Science

Junio 2026

v. 1.0.0

Índice general

1. Enunciado	3
2. Análisis de Componentes Principales (PCA)	5
2.1. Análisis Descriptivo y Matriz de Correlaciones	6
2.2. ACP Exploratorio: Selección del Número de Componentes	8
2.3. ACP con 2 Componentes Principales	9
2.3.1. Proceso numérico para el cálculo de la primera observación de la primera componente	10
2.3.2. Gráficos de las variables en el espacio de componentes	11
2.3.3. Gráficos de las observaciones en los nuevos ejes	13
2.3.4. Relación entre Componentes Principales y Variables	14
2.3.5. Variables suplementarias	16
3. Análisis clúster	19
3.1. Matriz de Distancias Euclídeas	19
3.2. Análisis Jerárquico: Determinación del número de Clústeres	21
3.3. Análisis clúster No Jerárquico	25
3.4. Evaluación de la Calidad de las Agrupaciones	26
3.5. Caracterización de Clústeres	27
3.5.1. Estadísticos descriptivos por clúster	27
3.5.2. Composición por especie e isla	28

1 Enunciado

El conjunto de datos 'penguins' de la librería 'seaborn' de Python contiene la siguiente información sobre diferentes especies de pingüinos:

- **species:** Es la especie de pingüino. Hay tres especies en el conjunto de datos: 'Adelie', 'Chinstrap' y 'Gentoo'.
- **island:** Representa la isla donde se recopilaron los datos. Las islas son 'Biscoe', 'Dream' y 'Torgersen'.
- **bill_length_mm:** Longitud del pico en milímetros.
- **bill_depth_mm:** Profundidad del pico en milímetros.
- **flipper_length_mm:** Longitud de la aleta en milímetros.
- **body_mass_g:** Masa corporal del pingüino en gramos.
- **sex:** Género del pingüino, con las categorías 'Male' (macho), 'Female' (hembra) o 'NaN' si la información no está disponible.

Con el objetivo de reducir el número de variables numéricas y explorar relaciones entre las características físicas de los pingüinos, así como entre las especies, realizar los siguientes apartados:

1. Calcular la matriz de correlaciones y su representación gráfica: ¿Cuáles son las variables más correlacionadas entre las características físicas de los pingüinos?
2. Realizar un análisis de componentes principales (PCA) sobre la matriz de correlaciones, calculando un número adecuado de componentes (máximo 4): Estudiar los valores de los autovalores obtenidos y las gráficas que los resumen. ¿Cuál es el número adecuado de componentes para representar eficientemente la variabilidad de las especies de pingüinos?
3. Realizar nuevamente el análisis de componentes principales sobre la matriz de correlaciones, esta vez indicando el número de componentes principales que hemos decidido retener. Sobre este análisis, contestar los siguientes apartados:
 - a) Escribe numéricamente el proceso para el cálculo de la primera observación en la primera componente.
 - b) Comentar los gráficos que representan las variables en los planos formados por las componentes: intenta explicar lo que representa cada componente en términos de las características físicas de los pingüinos.

- c) Sobre los gráficos que representan las observaciones en los nuevos ejes: teniendo en cuenta la posición de las especies de pingüinos en el gráfico, ¿cuáles destacan más en cada componente?
- d) Comenta la relación entre las Componentes Principales y las variables, las contribuciones de las Componentes Principales a la variabilidad explicada de las variables originales y la contribución de las variables a las Componentes Principales.
- e) Variables suplementarias: representa los centroides de cada especie y cada isla en un gráfico que tenga como ejes las componentes principales seleccionadas.

Tras explorar las características físicas de los pingüinos mediante el Análisis de Componentes Principales (ACP), ahora nos centraremos en evaluar la estructura de los grupos o clústeres existentes en el conjunto de datos. Utilizaremos técnicas de análisis de clúster, tanto jerárquicas como no jerárquicas, para identificar posibles agrupaciones basadas en las características (numéricas) de los pingüinos.

Los siguientes son los pasos y tareas a realizar:

1. Calcular la matriz de distancias: inicialmente, calcular la matriz de distancias entre las observaciones, empleando una medida de distancia adecuada, como la distancia euclídea.
2. Determinación del número de Clústeres - Análisis Jerárquico: utilizar métodos de clustering jerárquico para explorar la estructura de los datos. Aplicar técnicas como el dendrograma para visualizar y determinar el número óptimo de clústeres. Aplicar los procedimientos que conozcas que sirvan para decidir el número de clusters. Discutir las decisiones tomadas en este proceso.
3. Análisis de Clúster No Jerárquico: una vez decidido el número de clústeres, realizar un análisis de clúster no jerárquico (K-means) utilizando el número de grupos identificado en el paso anterior.
4. Evaluación de la Calidad de las Agrupaciones: evaluar la calidad de los clústeres formados utilizando el índice de silueta.
5. Caracterización de los Clústeres: caracterizar cada clúster basándose en estadísticos descriptivos y comparar las propiedades distintivas entre ellos.

Evaluación

La puntuación de la tarea está dividida en 2 partes:

- Análisis de Componentes Principales (5 puntos). Todos los apartados de esta parte tienen la misma puntuación.
- Análisis Cluster (5 puntos). Todos los apartados de esta parte tienen la misma puntuación.

2 Análisis de Componentes Principales (PCA)

El objetivo de este primer capítulo de la entrega es realizar un estudio sobre las características de los pingüinos obteniendo la mayor cantidad de información reduciendo la dimensionalidad. Para ello, aplicaremos un análisis de componentes principales pero antes, haremos un tratamiento inicial de los datos para obtener una visión general de la estructura del dataset.

Tras la lectura de datos, el objetivo es tener una visión clara de todas las variables que forman parte del dataset y obtener sus dimensiones. Posteriormente, se hará un estudio de los valores de los datos, para evitar outliers o valores perdidos.

species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	sex
Adelie	Torgersen	39.1	18.7	181	3750	Male
Adelie	Torgersen	39.5	17.4	186	3800	Female
Adelie	Torgersen	40.3	18.0	195	3250	Female
Adelie	Torgersen	36.7	19.3	193	3450	Female
Adelie	Torgersen	39.3	20.6	190	3650	Male
Adelie	Torgersen	38.9	17.8	181	3625	Female
Adelie	Torgersen	39.2	19.6	195	4675	Male
Adelie	Torgersen	41.1	17.6	182	3200	Female
Adelie	Torgersen	38.6	21.2	191	3800	Male
Adelie	Torgersen	34.6	21.1	198	4400	Male

Para tener el correcto tratamiento de los datos y preparar nuestro dataset para el PCA, debemos guardar las variables categóricas y eliminarlas para solo trabajar con las variables numéricas. También, eliminaremos aquellas con datos perdidos:

Tratamiento inicial del dataset

```
1 # Guardamos las variables categóricas como variables suplementarias
2 species = penguins['species'].copy()
3 island  = penguins['island'].copy()
4 sex     = penguins['sex'].copy()
5
6 # Seleccionamos únicamente las variables numéricas para el ACP
7 variables = ['bill_length_mm', 'bill_depth_mm', 'flipper_length_mm', 'body_mass_g']
8 datos = penguins[variables].copy()
9
10 print(f'Variables numéricas seleccionadas: {variables}')
11 print(f'Número de observaciones antes de eliminar NaN: {len(datos)}')
```

Tratamiento inicial del dataset

```
1 # Eliminamos filas con valores perdidos
2 mask_validos = datos.notna().all(axis=1)
3 datos = datos[mask_validos].reset_index(drop=True)
4 species = species[mask_validos].reset_index(drop=True)
5 island = island[mask_validos].reset_index(drop=True)
6 sex = sex[mask_validos].reset_index(drop=True)
7
8 print(f'Número de observaciones tras eliminar NaN: {len(datos)}')
9 datos.head()
```

Después del tratamiento de los datos, obtenemos los siguientes resultados:

```
1 Variables numéricas seleccionadas: ['bill_length_mm', 'bill_depth_mm',
  ↳ 'flipper_length_mm', 'body_mass_g']
2 Número de observaciones antes de eliminar NaN: 333
3 Número de observaciones tras eliminar NaN: 333
```

Como vemos, tenemos un dataset limpio en el que no hay datos faltantes. Podemos proceder con nuestro análisis y realizar un análisis descriptivo de las variables para estudiar la existencia de anomalías en los datos.

2.1. Análisis Descriptivo y Matriz de Correlaciones

Como paso previo a la realización del PCA para reducir la dimensionalidad de los datos, procedemos con un análisis descriptivo de las variables. Con esto, nuestro objetivo es encontrar anomalías en los datos: buscaremos valores fuera de rango o atípicos.

Para ello, hacemos un primer estudio de las métricas descriptivas, tanto las de tendencia como de dispersión: mínimo, percentiles, media, máximo, desviación estándar y varianza.

Tras ese análisis, obtenemos los siguientes datos:

	Mínimo	P25	Mediana	P75	Media	Máximo	Desv. Est.	Varianza	Datos Perdidos
bill_length_mm	32.0	40.0	44.0	49.0	44.0	60.0	5.0	30.0	0
bill_depth_mm	13.0	16.0	17.0	19.0	17.0	22.0	2.0	4.0	0
flipper_length_mm	172.0	190.0	197.0	213.0	201.0	231.0	14.0	196.0	0
body_mass_g	2700.0	3550.0	4050.0	4775.0	4207.0	6300.0	805.0	648372.0	0

Al observar estos datos vemos que no detectamos ninguna observación con algún valor fuera de rango, ni desviaciones muy grandes, por lo que concluimos que no hay datos fuera de rango ni atípicos.

Sin embargo, sí destacamos una propiedad del dataset y es que no todas las variables miden las mismas magnitudes, ya que las tres primeras miden longitudes mientras que la cuarta (*body_mass_g*) mide masa. Eso tiene unas consecuencias claras y es que las escalas entre las variables es diferente al ser la masa mucho más grande que la longitud. Esta diferencia hace imprescindible la estandarización de los datos para aplicar correctamente el Análisis de Componentes Principales.

A continuación, uno podría pensar que tendría todos los indicadores para poder aplicar el PCA, sin embargo, esta técnica no tiene sentido en variables independientes. Por tanto, debemos estudiar la correlación entre las variables. Obtenemos la matriz de Varianzas-Covarianzas:

$$C = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^T$$

donde X es la matriz de datos, $\bar{X}$ es el vector de medias y C la matriz de varianzas-covarianzas.

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
bill_length_mm	29.906333	-2.462091	50.058195	2595.623304
bill_depth_mm	-2.462091	3.877888	-15.947248	-748.456122
flipper_length_mm	50.058195	-15.947248	196.441677	9852.191649
body_mass_g	2595.623304	-748.456122	9852.191649	648372.487699


Sin embargo, como hemos preavisado anteriormente, las variables miden distintas magnitudes, luego sus valores no están estandarizados. Eso hace que las covarianzas no estén acotadas y por tanto, dificultan su interpretación. Para corregir este error, utilizamos la matriz de correlaciones, definida de la siguiente manera:

$$R = \frac{1}{n} \sum_{i=1}^n (Z_i - \bar{Z})(Z_i - \bar{Z})^T = \frac{1}{n} \sum_{i=1}^n Z_i Z_i^T$$

donde $Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j}$, $i \in n, j \in p$ para n el número de observaciones y p el número de variables y, $\bar{X}_j$ es la media de la variable j -ésima y s_j su desviación estándar.

	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g
bill_length_mm	1.000000	-0.228626	0.653096	0.589451
bill_depth_mm	-0.228626	1.000000	-0.577792	-0.472016
flipper_length_mm	0.653096	-0.577792	1.000000	0.872979
body_mass_g	0.589451	-0.472016	0.872979	1.000000

Para facilitar la comprensión de la matriz de correlaciones, procedemos a hacer una representación gráfica como mapa de calor:



Frente a esta representación vemos un claro agrupamiento de las variables. Visualmente, vemos una distinción en dos grupos (rojo y azul) en las que se traducirán las componentes principales.

Como interpretación de la matriz, vemos que las variables *body_mass_g* y *flipper_length_mm* están fuertemente relacionadas, prácticamente llegando a la linealidad (al tener un coeficiente 0,87 muy cercano a 1). Asimismo, estados dos variables también están correladas positivamente con la variable *bill_length_mm*.

Por el contrario, la variable *bill_depth_mm* está relacionada negativamente con el resto de variables (especialmente con *body_mass_g* y *flipper_length_mm* con $-0,47$ y $-0,58$, respectivamente).

Estas relaciones sugieren que los pingüinos más pesados son aquellos con las aletas y el pico más largo. Sin embargo, la profundidad del pico sigue un patrón distinto siendo a mayor profundidad menor masa y longitud (luego, un pingüino más pequeño).

2.2. ACP Exploratorio: Selección del Número de Componentes

Ahora, tras haber estudiado la correlación entre las variables, estamos en disposición de empezar el PCA. El objetivo en esta sección será realizar un análisis con todas las componentes posibles (4) y estudiar su explicación de la varianza para terminar seleccionando el número óptimo de estas.

Para ello, lo primero que haremos será estandarizar los datos para poder trabajar cómodamente con los datos. Para ello, reiteramos el proceso que habíamos seguido para calcular la matriz de correlaciones, creando nuevas variables estandarizadas definidas como:

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j}, i \in n, j \in p$$

donde n es el número de observaciones y p es el número de variables.

	bill_length_mm_z	bill_depth_mm_z	flipper_length_mm_z	body_mass_g_z
0	-0.896042	0.780732	-1.426752	-0.568475
1	-0.822788	0.119584	-1.069474	-0.506286
2	-0.676280	0.424729	-0.426373	-1.190361
3	-1.335566	1.085877	-0.569284	-0.941606
4	-0.859415	1.747026	-0.783651	-0.692852


Una vez hemos obtenido los datos estandarizados, sí estamos en disposición de calcular las componentes principales. Como no sabemos a priori cuál es el número óptimo de componentes principales, ponemos el máximo número posible de componentes. En este caso, solo hay cuatro variables, luego la matriz de varianzas-covarianzas es cuadrada de dimensión cuatro, por lo que a lo sumo habrá 4 autovalores, luego cuatro componentes principales que implicarán la total explicabilidad de la varianza.

Por tanto, para calcularlas, procederemos a calcular los autovalores asociados a las componentes principales. Esto es, calcular los valores λ que resuelven la ecuación $\det(\Sigma - \lambda I) = 0$. Tras el cálculo de los autovalores, obtenemos los siguientes resultados con los siguientes resultados en cuanto a varianza explicada y acumulada:

	Autovalor (λ)	Var. Explicada (%)	Var. Acumulada (%)
Componente 1	2.7536	68.6339	68.6339
Componente 2	0.7805	19.4529	88.0868
Componente 3	0.3698	9.2161	97.3029
Componente 4	0.1082	2.6971	100.0000

Cuadro 2.1: Descomposición en componentes principales (PCA)

Por tanto, ya hemos obtenido los autovalores de las 4 componentes principales; sin embargo, nuestro objetivo es reducir la dimensionalidad de los datos, por lo que no es la mejor práctica quedarse con todas las componentes, ya que no reduciríamos la dimensionalidad. Por tanto, nuestro objetivo es reducir la dimensionalidad perdiendo la mínima explicabilidad de varianza posible. Para nuestro análisis, consideramos que reducir la dimensionalidad bastante y obtener un porcentaje de varianza explicada acumulado superior al 80 % es un buen resultado. Por tanto, impondremos como umbral ese 80 % y veremos con cuántas componentes llegamos a ese umbral. Para ello, debemos decidir con cuántas Componentes Principales nos quedaremos basándonos en la varianza explicada acumulada y el gráfico del “Codo”:



Frente a este gráfico y los valores obtenidos vemos que el corte óptimo es con dos componentes al conseguir más de un 88 % de explicabilidad de la varianza (bastante por encima de nuestro umbral). La primera componente explica prácticamente un 69 % de la varianza total y la segunda más de un 19 %. Ahí impondremos nuestro corte puesto que ganancia con la tercera componente es muy pequeña y añadirla supondría tener casi la totalidad de la explicabilidad pero prácticamente no se reduciría la dimensionalidad y por tanto, no se satisfarían nuestros objetivos.

2.3. ACP con 2 Componentes Principales

Una vez hemos decidido quedarnos con las dos primeras componentes, procedemos a calcularlas. Ahora, el objetivo será volver a realizar el Análisis de Componentes Principales seleccionando únicamente dos componentes principales:

¹ Autovalores: CP1 = 2.7536 | CP2 = 0.7805
² Varianza explicada: CP1 = 68.63% | CP2 = 19.45%
³ Varianza acumulada (2 CP): 88.09%

Calculamos los autovectores asociados a los autovalores para obtener la matriz de transformación W y así poder obtener las componentes principales (direcciones que explican la máxima varianza) mediante el siguiente cambio de base $CP = ZW$.

Variable	Autovector 1	Autovector 2
bill_length_mm_z	0.453753	0.600195
bill_depth_mm_z	-0.399047	0.796170
flipper_length_mm_z	0.576825	0.005788
body_mass_g_z	0.549675	0.076464

Cuadro 2.2: Matriz de Transformación W (autovectores)

De esta manera, para calcular las posiciones de los puntos en el espacio de las componentes principales como base, simplemente tendremos que aplicar el cambio de base definido de la siguiente manera:

$$\begin{aligned}
 CP_1 = & 0,4538 \cdot \text{bill_length_mm}_z - 0,399 \cdot \text{bill_depth_mm}_z \\
 & + 0,5768 \cdot \text{flipper_length_mm}_z + 0,5497 \cdot \text{body_mass_g}_z
 \end{aligned}
 \tag{2.1}$$

$$\begin{aligned}
 CP_2 = & 0,6002 \cdot \text{bill_length_mm}_z + 0,7962 \cdot \text{bill_depth_mm}_z \\
 & + 0,0058 \cdot \text{flipper_length_mm}_z + 0,0765 \cdot \text{body_mass_g}_z
 \end{aligned}
 \tag{2.2}$$

2.3.1. Proceso numérico para el cálculo de la primera observación de la primera componente

Como hemos ido definiendo a lo largo del trabajo, debemos tener los datos estandarizados para poder proceder con el cálculo correcto de las componentes principales. Luego, nuestro primer paso será estandarizar los datos:

$$Z_{ij} = \frac{X_{ij} - \bar{X}_j}{s_j}, i \in n, j \in p$$

Una vez hemos estandarizado todos los datos, el siguiente paso será calcular la matriz de correlaciones, la cual coincidirá con la matriz de varianzas-covarianzas de la muestra estandarizada:

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (Z_i - \bar{Z})(Z_i - \bar{Z})^T = \frac{1}{n} \sum_{i=1}^n Z_i Z_i^T$$

Una vez hecho esto, calculamos las direcciones que maximizan la varianza explicada, esto es, calcular los vectores que maximicen la varianza del conjunto de datos. A partir del proceso de optimización de *multiplicadores de Lagrange*, donde queremos maximizar la función $v^T \Sigma v$ sujeto a la restricción de que $|v|^2 = v^T v = 1$. Por tanto, la función a optimizar aplicando el teorema de los multiplicadores de Lagrange:

$$L(v) = v^T \Sigma v - \lambda(v^T v - 1)$$

Para encontrar el máximo, derivamos e igualamos a 0:

$$\frac{\partial L}{\partial v} = 2\Sigma v - 2\lambda I v = 0 \implies (\Sigma - \lambda I) v = 0$$

Luego eso implica calcular los autovalores y los autovectores asociados (como hemos obtenido arriba). Siguiendo el procedimiento y añadiendo la restricciones de ortogonalidad, obtenemos que el resto de componentes principales se obtendrán mediante el cálculo del resto de autovalores y vectores propios de la matriz de varianzas-covarianzas. Una vez hemos hecho eso, obtenemos la matriz de cambio de base (matriz de transformación) $W = (v_1 \ v_2)$, donde v_1, v_2 son los autovectores calculados. Por tanto, ya tenemos los datos suficientes como para calcularla primera observación en la primera componente:

$$CP = ZW \Rightarrow CP_1 = Zv_1 \Rightarrow CP_1(z_1) = z_1 \cdot v_1 = v_{11} \cdot z_{bill_length} + v_{21} \cdot z_{bill_depth} + v_{31} \cdot z_{flipper_length} + v_{41} \cdot z_{body_mass} \quad (2.3)$$

donde v_{i1} son los coeficientes del vector v_1 . En particular, sustituyendo los valores obtenidos en el problema:

```

1 Valores estandarizados de la primera observación:
2   bill_length_mm_z = -0.896042
3   bill_depth_mm_z = 0.780732
4   flipper_length_mm_z = -1.426752
5   body_mass_g_z = -0.568475
6
7 Coeficientes del primer autovector (e_j1):
8   bill_length_mm_z: e_j1 = 0.453753
9   bill_depth_mm_z: e_j1 = -0.399047
10  flipper_length_mm_z: e_j1 = 0.576825
11  body_mass_g_z: e_j1 = 0.549675
12
13 Cálculo paso a paso de CP1 para la observación 1:
14  (-0.896042) x (0.453753) = -0.406582
15  (0.780732) x (-0.399047) = -0.311549
16  (-1.426752) x (0.576825) = -0.822986
17  (-0.568475) x (0.549675) = -0.312476
18
19 CP1 (calculado manualmente) = -1.853593
20 CP1 (calculado por sklearn) = -1.853593

```


2.3.2. Gráficos de las variables en el espacio de componentes

Previo a realizar el gráfico es importante dar una interpretación y estudiar la correlación que existe entre las variables y las componentes. Para ello, calcularemos las correlaciones entre ellas y las mostramos a continuación:

Variable	Componente 1	Componente 2
bill_length_mm_z	0.751829	0.529438
bill_depth_mm_z	-0.661186	0.702309
flipper_length_mm_z	0.955748	0.005106
body_mass_g_z	0.910762	0.067449

Cuadro 2.3: Correlaciones entre variables y componentes principales

Como podemos observar la primera componente principal CP_1 presenta prácticamente el total de la explicabilidad para las variables $flipper_length_mm_z$ y $body_mass_g_z$ al presentar una correlación de 0.9557 y 0.91, respectivamente. Además, es interesante señalar que las variables $bill_length_mm_z$ y $bill_depth_mm_z$ están correlacionadas con ambas componentes, luego habrá influencia de ambas componentes en las dos variables, destacando la correlación negativa con CP_1 .



Frente a la representación gráfica de las variables, vemos cómo la primera componente principal correlaciona fuertemente y de forma positiva con $bill_length_mm$, $flipper_length_mm$ y $body_mass_g$. Las tres variables apuntan hacia el lado derecho del gráfico, destacando particularmente que las variables $flipper_length_mm$ y $body_mass_g$ tienen prácticamente la dirección de la componente. De esto podemos deducir que esta componente puede interpretarse como un **índice de tamaño general del pingüino**, puesto que valores altos en CP_1 corresponden a individuos más grandes (mayor longitud de pico, aleta y masa).


En cuanto a la segunda componente, correlaciona fuertemente con $bill_depth_mm$. En general, esta componente relaciona la forma del pico puesto que es solo tiene relación con las variables $bill_depth_mm$ y $bill_length_mm$ (para las otras dos variables, su relación es prácticamente 0, luego no tiene casi capacidad explicativa sobre ellas). Por tanto, esta componente captura principalmente la **forma del pico** y complementándose con la primera componente es capaz de discernir entre profundidad y longitud,

diferenciando entre especies con pico más profundo y corto (*Adelie*, *Chinstrap*) frente a los de pico largo y menos profundo (*Gentoo*).

Por tanto, el espacio de componentes principales y la representación de los vectores de las variables en esta base nos dan una partición del espacio que nos ayuda a caracterizar las especies de los pingüinos presentes en cada hiperplano surgido de estas particiones. A continuación, visualizaremos la representación de los distintos grupos de pingüinos y veremos cómo las componentes principales y los hiperplanos formados nos dan la información sobre las características físicas de cada especie.

2.3.3. Gráficos de las observaciones en los nuevos ejes

Presentamos las observaciones en el plano generado por las componentes principales:



Hemos coloreado cada especie de un color y vemos cómo se distribuyen claramente. A partir de esta representación y el análisis que hemos realizado previamente nos permite caracterizar a cada especie a partir de ss especificaciones físicas:

- **Gentoo:** Es el grupo más separado y uniforme puesto que las otras dos especies tienen mayor interconexión entre ellas. A partir de las componentes principales, podemos deducir que se tratan de los pingüinos más grandes en general y con más masa (por su desplazamiento a la derecha de la representación). En cuanto al pico, podemos deducir que se trata de un pico alargado y fino en general, puesto que la mayoría de las observaciones se encuentran en el semiplano generado contrario al sentido del vector que indica la anchura del pico y en el semiplano en el sentido de la longitud del pico.
- **Adelie:** Realizando un análisis similar al que se ha hecho con la especie anterior, es algo más complejo diferenciarlo de la última especie (*Chinstrap*). Sin embargo, es la segunda componente la que nos da información para esta diferenciación. Puesto que el conjunto rojo tiende a estar más en el eje negativo de la segunda componente, esto quiere decir que su pico es corto. Son los pingüinos

que se encuentran más hacia la izquierda, por ende, son los pingüinos más pequeños de las tres especies. Además, como se encuentran mayoritariamente en el plano generado en el sentido del vector que mide la profundidad del pico, podemos concluir que tienen un pico corto y profundo. Por tanto, estos pingüinos se caracterizan por ser pequeños (tanto aletas como masa) y pico corto y profundo.

- **Chinstrap:** Estas observaciones se localizan en los cuadrados verdes de la representación. Recuperamos los argumentos seguidos anteriormente, mostrando un pingüino con el pico largo y profundo (pues es su localización en los hiperplanos generados por los autovectores). En cuanto a su tamaño, son algo más grandes que los Adelie pero también son pequeños (al estar en su mayoría en el eje negativo de la primera componente).

2.3.4. Relación entre Componentes Principales y Variables

Para evaluar si las componentes principales capturan eficazmente la información contenida en las variables originales y cuáles se explican mejor mediante las componentes, utilizamos la medida conocida como **cosenos al cuadrado**:

$$Cos_{ij}^2 = Corr^2(CP_i, X_j)$$

Esta métrica representa la proporción de varianza explicada de cada variable original que se explica mediante cada componente principal. En otras palabras, nos indica la cantidad de variabilidad total de una variable contenida en cada componente principal. Geométricamente, esto es la proyección de las variables originales sobre los vectores de la base (en este caso, las componentes principales). Como los datos han sido previamente estandarizados, tendremos una base ortonormal, luego, la norma será 1.

Así, deducimos que cuanto más cercano a 1 sea esta métrica, más explicabilidad tendrá esa componente acerca de la variable proyectada. Se mide al cuadrado para tener una métrica positiva y que esta sea comparable ya que no nos interesa si la relación es positiva o negativa, si no si está explicada.

De esta manera, obtenemos los siguientes resultados y vemos que las componentes están muy bien representadas por las componentes en suma:


Variable	Componente 1	Componente 2	Suma $\cos^2$
bill_length_mm_z	0.5652	0.2803	0.8456
bill_depth_mm_z	0.4372	0.4932	0.9304
flipper_length_mm_z	0.9135	0.0000	0.9135
body_mass_g_z	0.8295	0.0045	0.8340

Cuadro 2.4: Cosenos al cuadrado ($\cos^2$) — Calidad de representación de cada variable


Para verlo más gráficamente, y tener una intuición mejor de las representaciones, mostramos el mapa de calor generado. Como podemos ver en los valores, en suma, todas las variables tienen una explicabilidad mayor del 80 %, lo que supone una muy buena representatividad a cambio de lo perdido al reducir dimensionalidad.

En cuanto al poder explicativo, vemos que la primera componente es la que más fuerza tiene, siendo la que mayor aporte tiene para todas las variables. Destacamos su fuerza en las variables *flipper_length_mm_z*

y *body_mass_g_z* aportando prácticamente la totalidad de la explicabilidad de estas variables. De esta manera, fortalecemos nuestra teoría de que esta componente recoge las características físicas y de tamaño de los pingüinos, mientras que la segunda componente recoge las características del pico, teniendo mucho más peso en la variable menos respresentada *bill_depth_mm_z*.



Otra manera de verlo, para mostrar la representatividad de cada componente en cada variable es verlo mediante un diagrama de barras:



De nuevo, nos reafirmamos en nuestra teoría de que ninguna de las variables está completamente representada, pero prácticamente llegan al total de la explicabilidad reduciendo significativamente la dimensionalidad.


Asimismo, vemos la predominancia de la primera componente principal, satisfaciendo su proporcionalidad en la varianza explicada. De nuevo, en la única variable donde la segunda componente tiene más peso es en *bill_depth_mm_z*, fortaleciendo la hipótesis de que la segunda componente recoge las características relativas al pico.

Una vez hemos visto cómo explican las componentes principales a las variables originales, pasamos al proceso contrario: estudiamos las contribuciones de las variables a las componentes principales.

Para comprender cómo contribuye cada variable original a la construcción de las Componentes Principales, calculamos la contribución específica dada por:

$$Contribucion_{ji} = \cos^2_{ij} \sqrt{\lambda_i}, i = 1, \dots, k; j = 1, \dots, p$$

Esto nos permite cuantificar la influencia de cada variable en la definición de una componente. Así, obtenemos los siguientes resultado representados en un mapa de calor para tener una mejor comprensión de los resultados:



Hagamos un análisis componente a componente. En cuanto a la primera componente, vemos cómo los pesos se distribuyen relativamente de forma uniforme, con una mayor representación de las variables *flipper_length_mm_z* y *body_mass_g_z* lo que es coherente al estar estas variables más relacionadas con el tamaño del pingüino.

En cuanto a la segunda componente, vemos una clara predominancia *bill_depth_mm_z*, siendo la mayor contribución de una variable a cualquiera de las componentes. Vemos que en la segunda componente solo contribuyen las dos primeras variables referentes al pico (con una ayuda residual de 0.6 por parte de la variable *body_mass_g_z*) y confirmando que la segunda componente captura esencialmente la variabilidad en la profundidad del pico.

2.3.5. Variables suplementarias


El PCA se utiliza muchas veces para resumir y comprender las relaciones entre variables en un conjunto de datos. Sin embargo, es común que surjan nuevos elementos o variables que no estaban presentes en el

conjunto de datos original, a lo que llamamos **individuos suplementarios** (en el caso de observaciones) o **variables suplementarias** (en el caso de nuevas variables añadiendo características adicionales).

La inclusión de individuos y variables suplementarias en el ACP nos permite evaluar cómo se sitúan en relación con la estructura existente de las componentes principales.

Para estudiar la influencia de las variables categóricas, representar los centroides de estas categorías en los ejes de las componentes principales es clave. Esto es porque los centroides actúan como resúmenes de la tendencia central seguida en cada categoría, permitiendo visualizar y entender mejor las relaciones entre diferentes categorías y las componentes principales. El objetivo de esto es mostrar patrones y relaciones sutiles, añadiendo una dimensión adicional al análisis de la estructura de datos.

Dicho esto, mostramos los centroides de las dos variables categóricas que guardamos antes de empezar con el cálculo de las componentes principales. Veremos los patrones de distribución que muestran los pingüinos según su especie y la isla en la que habitan. Mostramos a continuación los resultados:



A partir de la anterior representación podemos extraer conclusiones representativas de la distribución de nuestros datos:

- **Centroides por especie:** El patrón más destacado es la clara separación de *Gentoo* respecto a *Adelie* y *Chinstrap*, cuyos centroides se ubican en la región negativa de CP1. Esto es totalmente coherente con la tabla de $\cos^2$: CP1 está dominado por *flipper_length_mm* y *body_mass_g*, es decir, CP1 representa fundamentalmente el tamaño corporal global. La posición de *Gentoo* en el lado positivo confirma que es la especie de mayor tamaño.

En cambio, *Adelie* y *Chinstrap* presentan un solapamiento casi total en CP1 (tamaños corporales similares), pero se separan notablemente en CP2. Como CP2 está asociado principalmente a *bill_depth_mm* y, en menor medida, a *bill_length_mm*, esta diferencia sugiere que ambas especies se distinguen más por la forma del pico que por el tamaño corporal. En conjunto, los dos centroides funcionan como una validación visual de la interpretación de los ejes de las componentes principales.

Este patrón también es consistente con el coeficiente de silueta promedio (0,4462 para $k = 3$): un valor moderado, ya que *Gentoo* forma un grupo bien separado y compacto, mientras que *Adelie* y *Chinstrap* se solapan parcialmente en el plano, lo que reduce la cohesión global de la partición en tres clusters.

- **Centroides por isla:** El patrón geográfico de las islas reproduce casi exactamente el patrón por especie: el centroide de *Biscoe* cae en la misma región que *Gentoo*, mientras que *Torgersen* y *Dream* se ubican en la zona de *Adelie/Chinstrap*. Esto refleja la distribución predominante en las islas de cada especie del dataset (*Gentoo* habita exclusivamente *Biscoe*; *textitChinstrap* exclusivamente *Dream*; *Adelie* está presente en las tres islas, predominando en *Torgersen*). Es decir, la isla actúa como una *aproximación* de la especie.

Finalizado este análisis, hemos completado todo el análisis de componentes principales y hemos visto cómo se traducen las componentes principales calculadas tanto en las variables numéricas del dataset como en su explicabilidad en las variables categóricas. Una vez exploradas las características físicas, nuestro siguiente objetivo será analizar la estructura de los grupos presentes. Para ello, pasaremos a realizar un análisis Cluster en el siguiente capítulo.

3 Análisis clúster

Tras explorar las características físicas de los pingüinos mediante el Análisis de Componentes Principales (ACP), ahora nos centraremos en evaluar la estructura de los grupos o clústeres existentes en el conjunto de datos. Utilizaremos técnicas de análisis de clúster, tanto jerárquicas como no jerárquicas, para identificar posibles agrupaciones basadas en las características (numéricas) de los pingüinos.

Para realizar el análisis de clústering, se deben satisfacer las siguientes condiciones:

- **Escala de las Variables:** Se cumple ya que trabajamos con la matriz de datos estandarizada para que no domine ninguna de las variables.
- **Ausencia de Valores Atípicos:** En el apartado anterior ya hemos verificado que no existía ningún dato atípico.
- **Tratamiento de Datos Perdidos:** También, previamente ya hemos verificado que no existen datos faltantes en el dataset.
- **Minimizar la correlación entre Variables:** Vamos a utilizar pocas variables numéricas, luego aunque algunas estén bastante relacionadas, también sirven para clasificar los grupos.

Estamos en disposición de comenzar el análisis.


3.1. Matriz de Distancias Euclídeas

El análisis de clústering implica una serie de pasos estructurados para formar grupos homogéneos de datos. El primero de ellos consiste en la evaluación del parecido entre observaciones, luego deberemos determinar la proximidad o similitud entre las observaciones utilizando **medidas de distancia**. Para tener una fácil interpretabilidad, hemos decidido tomar la distancia euclídea para nuestro problema.

Una vez hecho esto, representamos la matriz de distancias como un mapa de calor para tener una primera representación de los distintos grupos que puede haber en el conjunto de datos según su proximidad en las observaciones:

Frente a esta representación, el mapa de calor permite identificar la existencia de bloques de observaciones con distancias pequeñas entre ellas, pero con distancias más grandes entre los bloques. Como primer vistazo, podemos identificar claramente tres bloques (coherente con la existencia de tres especies y tres islas):

- **Observaciones 0-145:** Aproximadamente, este grupo de observaciones presenta una distancia muy pequeña entre ellas. Según la leyenda, la distancia entre estas observaciones no debe superar el 2, por los valores tomados, lo que supone observaciones cercanas, puesto que a partir de ahí las siguientes



observaciones empiezan a ser más distantes, superando la distancia de 4 unidades. Este grupo de observaciones se corresponde con la especie de pingüino *Adelie* en su mayoría.

- **Observaciones 145 - 212:** En este caso, supone el grupo más pequeño de observaciones similares entre ellas. En comparación, vemos (por el tipo de rayas) que este grupo tiene más similitud con el conjunto anterior que con el conjunto de observaciones que presentaremos a continuación. Las observaciones corresponde con la especie *Chinstrap*, lo cual vuelve a ser coherente.
- **Observaciones 212-333:** Finalmente, llegamos al grupo más homogéneo, al ser el que presenta un color mucho más claro. Se corresponde con el grupo de la especie *Gentoo* y gráficamente, vemos que es el grupo más diferente respecto a los dos anteriores puesto que en comparación con ellos, presenta un azul más fuerte.

Ante esta tesitura de discriminación de grupos por distancias entre las observaciones, está justificado el análisis clúster.

3.2. Análisis Jerárquico: Determinación del número de Clústeres

Los métodos de clasificación jerárquicos organizan los datos en una estructura arborescente, comenzando con grupos que son observaciones individuales, de forma que se van agrupando progresivamente en clústeres de niveles superiores.


Estos métodos no conocen previamente el número final de clústeres. Por ello, se siguen los siguientes pasos:

- Iniciar con tantos grupos como observaciones existan.
- Agrupar las dos observaciones más cercanas, reduciendo el número total de clústeres en uno.
- Continuar este proceso hasta que todas las observaciones estén agrupadas en un único clúster.

Observación. Como se pueden definir de diferentes maneras las distancias entre observaciones individuales y entre clústeres, con un mismo conjunto de datos podemos obtener **diferentes clasificaciones jerárquicas**.

Una herramienta útil para el clústering jerárquico son los mapas de calor que incorporan técnicas de reordenación basadas en la similitud. De esta forma, somos capaces de agrupar los elementos más similares, mejorando nuestra capacidad para encontrar agrupaciones y relaciones entre los datos.

A continuación, mostramos el mapa de calor con los datos reordenados para tratar de encontrar patrones intrínsecos:




Vemos cómo se vuelven a separar en tres grandes conjuntos de datos, sin embargo, esta vez en cada conjunto se forman otros subconjuntos, lo cual es coherente puesto que al ser de la misma especie en cada

Una primera métrica para calcular el número de clústeres es la distancia que ponemos para dividirlos. En este caso, consideramos que la **distancia de Ward** es una métrica clave para aplicarla en el problema. El objetivo de la métrica consiste en seleccionar la combinación de clústeres que minimiza el incremento de la varianza dentro de los clústeres resultantes. Para medirla, se minimiza la suma de cuadrados de las distancias entre las observaciones y el centroide del grupo fusionado:

donde

- Para ilustrar esta medida y su aplicación a la hora de formar clústeres, se utiliza el **dendograma**. Este es un gráfico con estructura de árbol en el que se visualizan las formaciones de grupos y la secuencia de fusiones entre ellos. Las alturas a las que se fusionan las distintas ramas representan las distancias entre los grupos que se combinan. A continuación, mostramos el dendograma obtenido en el problema:



22

en la calidad de las agrupaciones obtenidas. Para encontrar este número, nos apoyaremos en la siguientes medidas de bondad de ajuste:

1. **Variabilidad dentro de los conglomerados (WCSS):** Se mide la variabilidad dentro de los grupos, cuantificando lo lejos que está cada observación del centroide del grupo:

$$WCSS = \sum_{i=1}^K \sum_{j=1}^n d(x_{ij}, c_i)^2$$

donde K es el número de conglomerados, n es el número de observaciones en el grupo i y $d(x_{ij}, c_i)$ es la distancia del punto x_{ij} al centroide del grupo i .

2. **Variabilidad entre conglomerados (BCSS):** Mide la variabilidad entre los centroides de los conglomerados:

$$BCSS = \sum_{i=1}^K n_i \cdot d(c_i, c)^2$$


donde n_i es el número de datos en el grupo i , y $d(c_i, c)$ es la distancia entre el centroide del grupo i y el centroide general c .

3. **Variabilidad total (TSS):** Mide la variabilidad total de los datos, siendo la suma de las distancias al cuadrado entre las observaciones y el centroide general:

$$TSS = \sum_{i=1}^K \sum_{j=1}^n d(x_{ij}, c)^2$$

donde n es el número total de datos y $d(x_{ij}, c)$ es la distancia de x_{ij} al centroide general c .

Por tanto, para encontrar el número óptimo de conglomerados, recurrimos a las métricas anteriores. El objetivo será calcular $WCSS$ y aplicar el *método del codo* para encontrar el punto donde la gráfica se dobla (luego la pérdida de variabilidad pasa a ser insignificante y eso indica el número óptimo de clústers).



Vemos cómo a partir de $k = 3$ el decrecimiento de $WCSS$ es prácticamente nulo, luego proponemos $k = 3$ como el número óptimo de grupos. Esto indica que hay muy poca variabilidad dentro del conglomerado cuando dividimos el conjunto de datos en tres.


Para ratificar nuestra elección de $k = 3$, también empleamos el *método de la silueta*. El objetivo de este método es evaluar y graficar la calidad de los clústeres. El método otorga una medida acotada conocido como *coeficiente de silueta*,

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

donde $a(i)$ mide la buena agrupación de la observación i en el clúster y $b(i)$ mide la buena separación de los clústeres más cercanos de la observación i .

Este valor está claramente acotado entre -1 y 1 , indicando que está bien agrupada en el caso de un valor cercano a 1 , o por el contrario, la asignación a un clúster incorrecto en el caso de que el valor sea cercano a -1 .

Tras el análisis teórico de esta medida, obtenemos la siguiente representación con sus respectivos valores:




k	Silueta media
2	0.5308
3	0.4462
4	0.3982
5	0.3744
6	0.3642
7	0.3287
8	0.2992
9	0.2884
10	0.2871

Cuadro 3.1: Silueta media por número de clústers

Atendiendo a la propia definición del método de la silueta, el objetivo es encontrar el máximo global de la curva. En este caso, el método propone $k = 2$ como solución óptima. Sin embargo, conociendo el dataset, consideramos que esta elección podría ser demasiado simplista y no detectar correctamente diferencias clave entre grupos de observaciones. Por ello, seleccionaremos el siguiente máximo local $k = 3$, lo que sustenta nuestra elección anterior mediante el método del codo y con el número de clústeres que hemos ido considerando a lo largo del trabajo.

Observación. *Un breve comentario sobre lo que podría estar pasando en esta métrica es que a simple vista, con el dataset en negro, sin conocer previamente las características de las observaciones, se ven dos grupos de observaciones separados por un hiperplano. Por tanto, no es incorrecto el separar en dos grandes grupos de observaciones. Sin embargo, empleando el análisis de componentes principales, vemos que en uno de esos grandes grupos hay una subdivisión en otros dos grupos (según las direcciones de los vectores) y es por eso por lo que consideramos 3 clústeres, con el fin de captar estas diferencias.*

Tras la elección de $k = 3$ en el análisis jerárquico, las agrupaciones quedan de la siguiente manera (simulando la distribución de las especies de pingüinos):




Clúster	Observaciones
1	119
2	57
3	157
Total	333

Cuadro 3.2: Distribución de observaciones por clúster (jerárquico)

3.3. Análisis clúster No Jerárquico

Una vez decidido el número de clústeres, procederemos a realizar el análisis no jerárquico. Este algoritmo consiste en seleccionar $k = 3$ observaciones como centroides iniciales. A partir de ahí, iremos asignando a cada observación su clúster más cercano. Reiteraremos este proceso hasta cumplir la regla de parada o hasta llegar a la convergencia del método. Este algoritmo recibe el nombre de **K-means**. El objetivo de este algoritmo es encontrar el equilibrio de pesos entre todos los grupos para obtener la mejor agrupación de observaciones.

Tras aplicar el método con el número preseleccionado de $k = 3$, los resultados del algoritmo son los siguientes:



Clúster	Observaciones
1	129
2	119
3	85
Total	333

Cuadro 3.3: Distribución de observaciones por clúster (No jerárquico)

Como podemos apreciar, a diferencia del análisis no jerárquico, los clústeres se equilibran, ganando más peso el conjunto de observaciones verdes (azul en el caso del jerárquico). Esta representación se asemeja más a la real en separación por grupo de especie. Por tanto, como conclusión a esto, podemos considerar una buena práctica el realizar un primer análisis jerárquico para calcular el número de conjuntos y hacer las primeras agrupaciones y posteriormente, aplicar el no jerárquico para obtener una distribución más óptima.


3.4. Evaluación de la Calidad de las Agrupaciones

Una vez obtenidos los clústeres finales, debemos evaluar la bondad de los grupos obtenidos. Para ello, aplicaremos el gráfico de silueta, el cual consiste en calcular y representar el gráfico de silueta para cada observación dentro de los clústeres determinados.

De nuevo, recordemos que coeficientes cercanos a 1 implica una buena clasificación, a 0 es próximo a la frontera entre dos clústeres y coeficientes cercanos a -1 es una mala clasificación. Dicho esto, mostramos el gráfico obtenido:

En primer lugar, cabe señalar que un coeficiente de silueta promedio superior a 0.5 se considera indicativo de una estructura de agrupamiento razonable; luego 0.462, aunque sea ligeramente inferior a dicho umbral, sugiere que la partición en 3 clústeres es coherente y puede considerarse aceptable.

En términos generales, la mayoría de las observaciones presentan valores de silueta positivos, lo que indica



que están correctamente asignadas a su clúster y que la distancia a los elementos de su propio grupo es menor que la distancia a los elementos del clúster más cercano. Sin embargo, el clúster 2 es el único que contiene observaciones con silueta negativa, lo que refleja cierta ambigüedad en la asignación de algunos individuos y apunta a una separación menos clara respecto a los clústeres adyacentes.

Por otro lado, las barras correspondientes al clúster 1 son las más alargadas del gráfico, lo sugiere que este grupo está especialmente bien definido, con una mayor separación respecto a los demás clústeres y una frontera más nítida entre ellos (se puede ver claramente en la representación y son mayoritariamente las obseraciones correspondientes a la especie *Gentoo*). Finalmente, las observaciones con silueta negativa, cercana a cero o de menor longitud corresponden a pingüinos situados en la frontera entre clústeres, fundamentalmente entre las especies *Adelie* y *Chinstrap*, que comparten características similares en algunas de las variables consideradas en el análisis, lo que dificulta su diferenciación y provoca solapamientos en la solución de agrupamiento.

3.5. Caracterización de Clústeres

Una vez obtenidos y evaluados los clústeres finales mediante K-Means con $k = 3$, el último paso del análisis consiste en caracterizar cada grupo a partir de sus estadísticos descriptivos, su composición por especie e isla, y la distribución de las variables físicas. El objetivo es asignar una interpretación biológica a cada clúster, dotando de significado a los grupos identificados de forma puramente matemática mediante las variables explicativas.


3.5.1. Estadísticos descriptivos por clúster

La siguiente tabla recoge las medias, medianas y desviaciones típicas de las cuatro variables numéricas para cada uno de los tres clústeres obtenidos:

Cuadro 3.4: Estadísticos descriptivos por clúster (K-Means, $k = 3$)

Clúster	bill_length_mm			bill_depth_mm			flipper_length_mm			body_mass_g		
	Media	Med.	Desv.	Media	Med.	Desv.	Media	Med.	Desv.	Media	Med.	Desv.
0	38.28	38.30	2.26	18.12	18.10	1.16	188.63	189.00	5.72	3593.80	3550.00	407.49
1	47.57	47.40	3.11	15.00	15.00	0.99	217.24	216.00	6.59	5092.44	5050.00	501.48
2	47.66	47.50	3.87	18.75	18.80	1.14	196.92	197.00	6.35	3898.24	3900.00	414.41

La inspección de la tabla revela diferencias muy marcadas entre los clústeres. A continuación detallamos las características de cada uno de ellos.



3.5.2. Composición por especie e isla

Antes de interpretar los estadísticos, es fundamental conocer qué especies y qué islas componen cada clúster, pues esto permite vincular las características numéricas con la especie de los pingüinos.

Cuadro 3.5: Composición de especies por clúster (K-Means, $k = 3$)

Clúster	<i>Adelie</i>	<i>Chinstrap</i>	<i>Gentoo</i>	Total
0	124	5	0	129
1	0	0	119	119
2	22	63	0	85
Total	146	68	119	333

La tabla confirma que el algoritmo recupera casi perfectamente la estructura de especies:

- **Clúster 1** → **Gentoo** (119/119, pureza del 100 %): separación perfecta, reflejo de su morfología claramente distinta.
- **Clúster 0** → **Adélie** (124/129, pureza del 96 %): asignación casi perfecta; 5 *Chinstrap* no están bien clasificados debido a la similitud morfológica con los *Adélie*.
- **Clúster 2** → **Chinstrap** (63/85, pureza del 74 %): el menos puro, con 22 *Adélie* absorbidos, lo que evidencia el solapamiento morfológico entre ambas especies.

Este solapamiento entre especies en los clústeres 0 y 2 es lo que no determina de detectar el algoritmo, por lo que vemos reflejado esa bajada en las métricas de la sombra y del codo al tomar $k = 3$ a la hora de realizar los clústeres. En caso de haber tomado $k = 2$, se hubiese separado perfectamente en dos grupos (al haber separado nuestro clúster 1 actual y unir el 0 y el 2) pero no hubiésemos obtenido el total de la granularidad.

En conjunto, K-Means agrupa correctamente 306 de 333 individuos, lo que supone una tasa de acierto aproximada del 91.9 %, sin haber utilizado la etiqueta de especie en ningún momento.

En cuanto a la distribución geográfica, los clústeres obtenidos reflejan implícitamente la separación por especie más que por isla (ya que en cada isla hay una especie predominante, pero no son las únicas por isla) :

Cuadro 3.6: Composición de islas por clúster (K-Means, $k = 3$)

Clúster	<i>Biscoe</i>	<i>Dream</i>	<i>Torgersen</i>	Total
0	37	54	38	129
1	119	0	0	119
2	7	69	9	85
Total	163	123	47	333

- El **Clúster 1** está formado íntegramente por pingüinos de *Biscoe* (119/119), lo que apunta a los *Gentoo* son los pingüinos dominantes de la isla, con menor representación de las otras especies y clústeres.
- **Clúster 2** concentra el 81 % de sus individuos en *Dream* (69/85), correspondiendo probablemente a los *Chinstrap*, especie predominante en dicha isla.
- **Clúster 0** es el más heterogéneo geográficamente, mezclando las tres islas (*Biscoe*: 37, *Dream*: 54, *Torgersen*: 38), lo que sugiere una correspondencia con los *Adélie*, distribuidos por todo el archipiélago.

En conjunto, el algoritmo captura la estructura morfológica subyacente del dataset, siendo la distribución geográfica un efecto derivado de los hábitats propios de cada especie.

En cuanto a la clasificación morfológica de los clústeres:

Clúster 0 — Pingüinos pequeños con pico corto y profundo

Este clúster, formado por **119 observaciones**, es el que recoge los pingüinos de menor tamaño. Sus características más destacadas son:

- **Longitud del pico:** la más corta de los tres grupos, con una media de 38.28 mm y una mediana prácticamente idéntica (38.30 mm), lo que indica una distribución muy simétrica. La desviación estándar de 2.26 mm es la más pequeña de los tres clústeres, reflejando una gran homogeneidad en esta variable.
- **Profundidad del pico:** con una media de 18.12 mm, es la segunda más alta, lo que define un pico relativamente profundo en comparación con su longitud. La baja dispersión (desv. 1.16 mm) confirma que esta característica es uniforme dentro del grupo.
- **Longitud de la aleta:** la más reducida de los tres clústeres (media 188.63 mm, mediana 189.00 mm), con una desviación típica de 5.72 mm que indica un grupo compacto.
- **Masa corporal:** la menor de todos los grupos, con una media de 3.593,80 g y una mediana de 3.550 g. La desviación típica (407.49 g) es la más baja de los tres clústeres, evidenciando que se trata del grupo más homogéneo en términos de tamaño.

En síntesis, podemos concluir que los pingüinos *Adélie* (conjunto representativo del clúster) son los más pequeños del dataset en todas las dimensiones corporales medidas (aleta, masa y longitud de pico), pero presentan un pico relativamente profundo. Este perfil morfológico, unido a la escasa dispersión interna, hace del Clúster 0 un grupo muy bien definido y cohesionado, lo que es coherente con los valores de silueta positivos y moderados observados para este grupo en el apartado anterior.

Clúster 1 — Pingüinos grandes con pico largo y aleta extensa

El Clúster 1, integrado por **119 observaciones**, se distingue por ser el grupo más diferenciado y compacto del análisis, como ya anticipaba el gráfico de silueta, donde sus barras eran las más alargadas. Sus características son:

- **Longitud del pico:** con una media de 47.57 mm, similar al Clúster 2 (47.66 mm), pero con una desviación estándar notablemente inferior (3.11 mm frente a 3.87 mm), lo que indica mayor homogeneidad interna.
- **Profundidad del pico:** la más baja de los tres grupos (media 15.00 mm, mediana 15.00 mm), con la desviación estándar más pequeña de todos (0.99 mm). Esta combinación de pico largo y poco profundo diferencia morfológicamente a los *Gentoo* de las demás especies, y explica por qué la segunda componente principal del ACP separa a este grupo en el eje de CP2.
- **Longitud de la aleta:** la mayor de los tres clústeres, con una media de 217.24 mm (mediana 216.00 mm). La diferencia respecto al Clúster 0 supera los 28 mm, una brecha estadísticamente muy significativa que justifica la clara separación de *Gentoo* en el plano ACP.
- **Masa corporal:** es el grupo de pingüinos más pesados por una amplia diferencia, con una media de 5.092,44 g y una mediana de 5.050 g. La desviación estándar (501.48 g) es la mayor de los tres clústeres, lo que refleja que, aunque son los más grandes, existe una variabilidad interna no despreciable.

Los pingüinos *Gentoo* representan, por tanto, el perfil de **mayor tamaño corporal global**: mayor masa, mayor longitud de aleta y pico más largo, pero con un pico notablemente menos profundo que las otras dos especies. Esta combinación hace que el Clúster 1 sea el más fácilmente separable tanto en el plano de

las componentes principales como en el propio algoritmo de *clustering*, lo que se traduce en los valores de silueta más elevados del análisis.

Clúster 2 — Pingüinos de tamaño intermedio con pico largo y profundo

El Clúster 2, con **85 observaciones**, es el grupo menos numeroso y también el más heterogéneo internamente. Es el que presentaba mayor ambigüedad en el gráfico de silueta, con algunas observaciones de coeficiente negativo, reflejo de su mayor solapamiento con el Clúster 0. Sus características son:

- **Longitud del pico:** la media más alta de los tres grupos (47.66 mm, prácticamente igual al Clúster 1), pero con la mayor desviación estándar (3.87 mm). Esto indica que, aunque los *Chinstrap* tienen picos largos, existe mayor variabilidad en esta medida que en las otras especies (teniendo en cuenta que esta también se ve modificada por la longitud de pico significativamente menor de los *Adélie* recogidos en este grupo).
- **Profundidad del pico:** la más elevada de todos los clústeres (18.75 mm de media, 18.80 mm de mediana). Esta es la variable clave que diferencia al Clúster 2 del Clúster 1 (*Gentoo*), ya que ambos comparten longitudes de pico similares pero difieren sustancialmente en la profundidad. La desviación estándar (1.14 mm) es comparable a la del Clúster 0, mostrando consistencia interna en esta dimensión.
- **Longitud de la aleta:** con una media de 196.92 mm (mediana 197.00 mm), ocupa una posición intermedia entre el Clúster 0 (188.63 mm) y el Clúster 1 (217.24 mm). La desviación típica (6.35 mm) es coherente con las demás.
- **Masa corporal:** con una media de 3.898,24 g, es ligeramente superior a la del Clúster 0 (3.593,80 g) pero muy inferior a la del Clúster 1 (5.092,44 g). La mediana (3.900 g) confirma la simetría de la distribución. La desviación estándar (414.41 g) es similar a la del Clúster 0, apuntando a una dispersión interna moderada.


Los *Chinstrap* (especie predominante en este conjunto) presentan el perfil de **tamaño corporal intermedio con pico largo y especialmente profundo**. La combinación de longitud y profundidad elevadas en el pico es la característica más distintiva de este grupo. Sin embargo, la similitud en masa corporal y longitud de aleta con los *Adélie* explica por qué algunos individuos de ambos grupos presentan valores de silueta negativos o cercanos a cero: la frontera entre los Clústeres 0 y 2 es la menos nítida de todo el análisis, y el principal criterio de separación es la longitud del pico.

Perfil comparativo y conclusiones

Para facilitar la comparación entre clústeres, sintetizamos sus características en la siguiente tabla de perfiles estandarizados, expresados como distancia a la media global en desviaciones estándar:

Cuadro 3.7: Perfil de medias estandarizadas por clúster (distancia a la media global)

Clúster (Especie)	bill_length	bill_depth	flipper_length	body_mass
0 (<i>Adélie</i>)	−1.04	+0.49	−0.88	−0.76
1 (<i>Gentoo</i>)	+0.65	−1.10	+1.16	+1.10
2 (<i>Chinstrap</i>)	+0.67	+0.80	−0.29	−0.38



El perfil estandarizado confirma de manera muy visual las conclusiones obtenidas:

- El **Clúster 0** (*Adelie*) presenta valores negativos en longitud del pico, aleta y masa (por debajo de la media global), pero un valor positivo moderado en profundidad del pico. Son los pingüinos más pequeños, pero con el pico proporcionalmente profundo.
- El **Clúster 1** (*Gentoo*) destaca con los valores más extremos: fuertemente positivos en aleta y masa y el valor más negativo en profundidad del pico. Esta polarización explica su excelente separación en el plano ACP y sus altos coeficientes de silueta.
- El **Clúster 2** (*Chinstrap*) muestra la combinación más singular: positivo tanto en longitud como en profundidad del pico, pero con aleta y masa en torno a la media o ligeramente por debajo. Es el grupo con el pico morfológicamente más prominente en ambas dimensiones.

En definitiva, el análisis cluster no jerárquico ha logrado identificar de forma totalmente autónoma los tres grupos morfológicos presentes en el dataset, que coinciden casi en su totalidad con las tres especies de pingüinos. La separación entre *Gentoo* y las otras dos especies es la más pronunciada, sustentada principalmente por las variables de tamaño corporal (masa y aleta) recogidas en la primera componente principal. Por su parte, la distinción entre *Adelie* y *Chinstrap* es más sutil y descansa fundamentalmente en la longitud del pico: ambas especies comparten un tamaño corporal similar, pero los *Chinstrap* poseen un pico notablemente más largo, lo que queda capturado por la segunda componente principal del ACP y permite al algoritmo K-Means separarlos correctamente.