
Tarea de Series Temporales

 **nticmaster**



U N I V E R S I D A D
COMPLUTENSE
M A D R I D

Carlos San Román Cazorla

Universidad Complutense de Madrid

Máster de IA, Big Data y Data Science

Junio 2026

v. 1.0.0

Índice general

1. Enunciado	3
2. Introducción	4
2.1. Descripción del dataset	4
2.2. Objetivo	4
2.3. Representación gráfica y descomposición	4
2.3.1. Descomposición de la serie	6
2.4. División Train / Test	7
3. Modelos de suavizado exponencial	8
3.1. Modelo de alisado simple	8
3.2. Método de alisado doble de Holt	9
3.3. Holt-Winters	9
3.3.1. Comparación de modelos sobre la serie original	10
3.3.2. Expresión algebraica del modelo Holt-Winters multiplicativo	11
3.4. Holt-Winters sobre la serie transformada	11
3.4.1. Transformaciones aplicadas	11
3.4.2. Resultados sobre la serie transformada	12
4. Modelo SARIMA	15
4.1. Metodología Box-Jenkins	16
4.1.1. Homocedasticidad: transformación Box-Cox	16
4.1.2. Estacionariedad en media: diferenciación	16
4.2. Identificación del modelo: ACF y PACF	17
4.3. Estimación y selección del modelo	18
4.4. Expresión algebraica del modelo	22
4.5. Predicciones e intervalos de confianza	23
5. Conclusiones	24
5.1. Comparación de modelos: Holt-Winters vs SARIMA	24

1 Enunciado

Escoger una serie con estacionalidad de la que tengamos unos 150 valores observados aproximadamente. Podéis encontrar algunos ejemplos en Kaggle, en el INE, etc.

Se deberá realizar una memoria en PDF justificando todos los pasos realizados, así como el código en Python. La memoria debe de tener un máximo de 20 páginas.

Índice

1. Introducción: Presentación de la serie a analizar. Descripción de la misma y objetivo que se persigue con su estudio.
2. Representación gráfica y descomposición de la misma.
3. Para comprobar la eficacia de los métodos de predicción que vamos a hacer en los siguientes apartados reservamos los últimos datos observados (un periodo en las series estacionales o aproximadamente 10 observaciones) para comparar con las predicciones realizadas por cada uno de los métodos. Luego ajustamos los modelos sobre la serie sin esos últimos datos en los siguientes apartados.
4. Encontrar el modelo de suavizado exponencial más adecuado. Para dicho modelo, representar gráficamente la serie observada y la serie suavizada con las predicciones para un periodo que se considere adecuado. Escribir la expresión del modelo obtenido. Explicar detalladamente los pasos a realizar y su justificación.
5. Representar la serie y las funciones de autocorrelación y autocorrelación parcial. Decidir qué modelo puede ser ajustado. Ajustar el modelo adecuado comprobando su idoneidad. (Sintaxis, tablas de los parámetros estimados y gráficos) Explicar detalladamente los pasos a realizar y su justificación.
6. Escribir la expresión algebraica del modelo ajustado con los parámetros estimados.
7. Calcular las predicciones y los intervalos de confianza para las unidades de tiempo que se considere oportuno (detallar el porqué de esas unidades), dependiendo de la serie, siguientes al último valor observado. Representarlas gráficamente.
8. Comparar las predicciones obtenidas con cada uno de los métodos para los valores que se reservaron en el apartado 3, tanto gráfica como numéricamente. Conclusiones.

2 Introducción

2.1. Descripción del dataset

El dataset utilizado es el **UFO Sightings Scrubbed**, disponible públicamente en Kaggle, que recoge más de 80.000 avistamientos de OVNI's registrados en todo el mundo. El dataset incluye columnas descriptivas como la localización (ciudad, estado, país), la duración del avistamiento y comentarios sobre el mismo. Para este análisis, únicamente nos interesa estudiar cuántos avistamientos ocurren por unidad de tiempo, por lo que hemos reducido el dataset para representarlo como una serie temporal de la forma *unidad de tiempo – número de avistamientos*.

Para construir una serie temporal con suficiente densidad y estacionalidad, se ha optado por:

- **Agregar los avistamientos por mes** (unidad temporal = 1 mes).
- **Filtrar desde enero de 1990**, ya que antes de esa fecha los registros son muy escasos y no permiten identificar patrones estacionales fiables.

Esto nos deja con **293 observaciones mensuales (enero 1990 – mayo 2014)**, cumpliendo holgadamente el requisito mínimo de aproximadamente 150 observaciones.

2.2. Objetivo

El objetivo del análisis es modelar la serie temporal de avistamientos de OVNI's y predecir el número de avistamientos para los **próximos 12 meses** utilizando los modelos de series temporales vistos en clase: modelos de suavizado exponencial (Holt-Winters) y modelos SARIMA. Finalmente, se comparan ambos métodos para determinar cuál ofrece mejores predicciones.

2.3. Representación gráfica y descomposición

Al no tener el dataset la forma adecuada para ser representado como serie temporal, lo primero que debemos afrontar es la transformación del dataset para poder trabajar con estos datos. Como hemos mencionado anteriormente, los datos vienen desagregados hasta el nivel de horas, luego debemos agruparlos para poder observar una estacionalidad clara y poder tener una patrones que el modelo pueda captar. Para tratar los datos, emplearemos el siguiente código:

División Train y Test

```
1 # Carga del CSV original
2 df_raw = pd.read_csv("ufo_sightings_scrubbed.csv", low_memory=False)
3 print(f"Filas originales: {len(df_raw):,}")
4 print("Columnas:", df_raw.columns.tolist())
5
6 # Parseo de fechas y agregación mensual
7 df_raw["datetime"] = pd.to_datetime(df_raw["datetime"], errors="coerce")
8 df_raw = df_raw.dropna(subset=["datetime"])
9
10 monthly_all = (
11     df_raw.groupby(df_raw["datetime"].dt.to_period("M"))
12     .size()
13     .reset_index(name="avistamientos")
14 )
15 monthly_all["fecha"] = monthly_all["datetime"].dt.to_timestamp()
16 monthly_all = monthly_all.sort_values("fecha").reset_index(drop=True)
17
18 # Filtrar desde 1990 (serie densa y con estacionalidad visible)
19 monthly = monthly_all[monthly_all["fecha"] >= "1990-01-01"].reset_index(drop=True)
20 monthly.index = pd.DatetimeIndex(monthly["fecha"], freq="MS")
21 monthly = monthly[["avistamientos"]]
```

Una vez construida la serie temporal, la representamos gráficamente para tener una primera impresión de su comportamiento:




Figura 2.1: Avistamientos de OVNI's por mes (1990–2014).

Podemos observar una **clara tendencia creciente** en los avistamientos a lo largo del tiempo, con picos estacionales que sugieren una posible influencia de factores externos o patrones de reporte (vemos que ese aumento de registros se empieza a dar a partir de los años 2000, luego puede que esté bastante vinculado al creciente uso de internet por parte de las personas, luego mayor facilidad para compartir los hallazgos, por lo que es más fácil el registro de observaciones). La serie muestra un comportamiento **no estacionario**, lo que indica que se necesitarán técnicas de modelado adecuadas para capturar tanto la tendencia como la **estacionalidad** presentes en los datos (visualmente parece de un año). Asimismo, se aprecia un aumento de la varianza en los últimos años, lo que indica que la serie es **heterocedástica**.

2.3.1. Descomposición de la serie

Dado que la amplitud de la estacionalidad crece a medida que aumentan los años, se detecta una característica clásica de las series con tendencia creciente. Además, como esta amplitud va creciendo, para descomponer la serie, la mejor aproximación es la descomposición multiplicativa. De esta manera podemos descomponer de la siguiente manera

$$X_t = T_t \cdot S_t \cdot Z_t$$

donde T_t, S_t, Z_t son las componentes de tendencia, estacionalidad y aleatoria respectivamente.



Figura 2.2: Descomposición multiplicativa de la serie de avistamientos de OVNI.

La descomposición confirma la clara tendencia creciente, especialmente pronunciada desde el año 2000 (posiblemente por el aumento de registros de datos con la aparición de internet). Asimismo, detecta una estacionalidad anual bien definida, con picos en verano (posiblemente porque con las buenas temperaturas, la gente hace más vida nocturna, luego más facilidad para observar OVNI) y finalmente, unos residuos con varianza uniforme a partir de los años 2000, asemejándose al ruido blanco, siendo lo deseable de cara a la predicción y modelización.

A continuación, veremos cómo se comporta nuestra descomposición eliminando el factor aleatorio respecto de la serie original. Para ello, realizamos la superposición de la tendencia y la componente estacional y vemos que se mantiene el patrón, luego tenemos una buena descomposición:




Figura 2.3: Serie original, ajustada estacionalmente y tendencia superpuestas.

2.4. División Train / Test

Para comprobar la eficacia de los métodos de predicción, reservamos los **últimos 12 meses** (un periodo estacional completo, de junio 2013 a mayo 2014) como conjunto de test. El entrenamiento se realiza sobre los 281 meses restantes.




Figura 2.4: División de la serie en Train (azul) y Test (rojo).

En los capítulos posteriores, continuaremos el análisis desde el punto de vista del modelado y la predicción. Estos se dividirán en dos capítulos siguiendo con la estructura que se vio en clase: un primer capítulo dedicado al uso de modelos de suavizado exponencial y un segundo capítulo, enfocado en el uso de modelo ARIMA (en este caso, al ser una serie estacional, nos centraremos en su generalización SARIMA para captar mejor la componente estacional).

3 Modelos de suavizado exponencial

En este capítulo aplicamos los modelos de suavizado exponencial de forma progresiva, comenzando por los más simples e incorporando complejidad hasta llegar al modelo de Holt-Winters, el más adecuado para series con tendencia y estacionalidad. Una vez que hemos obtenido la descomposición de la serie temporal $X_t = T_t \cdot S_t \cdot Z_t$, el objetivo será utilizar estas componentes para realizar predicciones. Como hemos comentado, en este capítulo veremos los métodos de suavizado, los cuales se basan en modelos que se ajustan a la evolución de la serie dando más peso a las observaciones más recientes que a las alejadas para realizar la predicción.

3.1. Modelo de alisado simple

El primer método aplicado es el **modelo de alisado simple**, indicado para series sin tendencia ni estacionalidad. Dado que nuestra serie presenta ambas características, podemos anticipar que no será un buen predictor. Por tanto, modelizamos la serie de la siguiente manera:

Sea α el factor de ponderación, las predicciones para los valores futuros vendrán dadas por

$$\hat{x}_{t+1} = \alpha \sum_{k=0}^{\infty} (1 - \alpha)^k x_{t-k}$$

La variación de α se hace en función del peso que se le quiera dar a las últimas observaciones (mayor α para más peso en los valores recientes).




Figura 3.1: Valores observados, suavizado simple y predicción para 12 meses.

El modelo de alisado simple estima un parámetro $\alpha = 0,7774$, lo que indica una alta sensibilidad a las observaciones recientes. Como era de esperar, la **predicción es una recta** (al ser el modelo lineal respecto a las observaciones), incapaz de capturar ni la tendencia ni la estacionalidad de la serie.

3.2. Método de alisado doble de Holt

Para tratar de mejorar la predicción y solventar los problemas que nos ofrecía el método anterior, aplicamos el **método de alisado doble de Holt**, indicado para series con tendencia pero sin estacionalidad. Podemos intuir que tampoco será el mejor modelo al existir estacionalidad en la serie que estamos estudiando.

La ecuación de predicción de este modelo para valores futuros supuesto que hemos observado hasta el instante n es:

$$\hat{x}_{n+m} = L_n + b_n \cdot m$$

donde $L_t = \alpha \cdot x_t + (1 - \alpha)(L_{t-1} + b_{t-1})$ es la estimación de tendencia y $b_t = \beta(L_t - L_{t-1}) + (1 - \beta) \cdot b_{t-1}$ es la estimación de la pendiente.




Figura 3.2: Comparación entre el suavizado simple, el doble (Holt) y los valores observados.

El modelo Holt sí es **capaz de capturar la tendencia creciente** de la serie, pero al seguir siendo un modelo lineal, es incapaz de capturar los patrones estacionales. Por tanto, tampoco obtenemos buenas predicciones.

Observación: En este caso simplemente hemos estudiado el modelo desde un punto de vista aditivo, ya que la serie no cumplía con los requisitos ideales para este modelo. En los siguientes modelos haremos estas distinciones y nos quedaremos con el que consideremos mejor.

3.3. Holt-Winters

Finalmente, llegamos al último modelo visto de los modelos de suavizado. El modelo de **Holt-Winters** es el más adecuado para series con tendencia y estacionalidad. Comparamos las cuatro combinaciones

posibles de tendencia (aditiva/multiplicativa) y estacionalidad (aditiva/multiplicativa), optimizando los parámetros α , β , γ por máxima verosimilitud.

3.3.1. Comparación de modelos sobre la serie original

Modelo	α	β	γ	AIC	BIC
(add, add)	0.3662	0.0006	0.2250	2343.79	2402.01
(add, mul)	0.2214	0.0003	0.2791	2359.27	2417.48
(mul, add)	0.3937	0.0001	0.2206	2344.40	2402.61
(mul, mul)	0.2171	0.0001	0.2818	2361.86	2420.07

Cuadro 3.1: Comparación de modelos Holt-Winters por AIC y BIC.

En términos de **bondad de ajuste** (AIC y BIC), el mejor modelo es el **aditivo-aditivo** (trend=add, seasonal=add) con AIC = 2343.79. Sin embargo, la selección del modelo predictor requiere comparar sobre el conjunto de test.




Figura 3.3: Comparación de los cuatro modelos Holt-Winters sobre train y test.

Ante estas representaciones y predicciones en el conjunto de test, visualmente, parece que el que mejor aproxima o detecta los patrones del test es el modelo 4 (multiplicativo-multiplicativo). Para no tomar la decisión visualmente y tener un fundamento detrás en el que no incurra el factor humano, comparamos los modelos mediante métricas de bondad de ajuste en el conjunto de test:

Modelo	MAE	RMSE	MAPE (%)
(add, add)	176.15	197.06	51.34
(add, mul)	140.64	163.82	53.76
(mul, add)	183.53	202.50	51.58
(mul, mul)	123.92	154.51	53.96

Cuadro 3.2: Métricas de error de los modelos Holt-Winters sobre el conjunto test.

Ante estas métricas de bondad de ajuste en el conjunto de test, aunque el modelo aditivo-aditivo era el mejor en términos de AIC, el **modelo multiplicativo-multiplicativo** (trend=mul, seasonal=mul) es el que mejor predice sobre el conjunto de test, con **MAE = 123.92** y **RMSE = 154.51**. Por tanto, optamos por este modelo para la obtención de predicciones.

3.3.2. Expresión algebraica del modelo Holt-Winters multiplicativo

El modelo multiplicativo-multiplicativo combina tres ecuaciones de suavizado:

$$\ell_t = \alpha \frac{y_t}{s_{t-m}} + (1 - \alpha)(\ell_{t-1} + b_{t-1}) \quad (3.1)$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1} \quad (3.2)$$

$$s_t = \gamma \frac{y_t}{\ell_t} + (1 - \gamma)s_{t-m} \quad (3.3)$$

La predicción h pasos adelante es $\hat{y}_{t+h} = (\ell_t + h \cdot b_t) \cdot s_{t+h-m}$ donde $m = 12$ (estacionalidad anual) y los parámetros estimados son:

$$\alpha = 0,2171, \quad \beta = 0,0001, \quad \gamma = 0,2818 \quad (3.4)$$

3.4. Holt-Winters sobre la serie transformada

Tras el análisis realizado, vemos que no hemos obtenido un mal análisis, sin embargo, ninguno de los modelos entrenados termina de ajustarse bien a los datos del test, siendo incapaz de predecir una bajada más atenuada en observaciones después del mes de julio. Para tratar de solventar estas diferencias, podemos aplicar métodos que ayuden a mejorar la calidad de la predicción. Dado que la serie presenta heterocedasticidad y tendencia positiva, procedemos a aplicar una **transformación logarítmica y diferenciación** para conseguir las condiciones de homocedasticidad y estacionariedad necesarias para una mejor predicción.

3.4.1. Transformaciones aplicadas

A continuación, detallaremos paso a paso los procedimientos seguidos para conseguir la serie con las características deseadas para la predicción:

1. **Transformación logarítmica:** $z_t = \log(y_t + 400)$, donde se suma 400 para garantizar valores positivos. Esto estabiliza la varianza, consiguiendo que la serie sea homocedástica (o al menos tenga la varianza acotada).




Figura 3.4: Serie en escala logarítmica.

2. **Diferenciación:** $w_t = z_t - z_{t-1}$, para eliminar la tendencia y conseguir así la estacionariedad buscada.




Figura 3.5: Serie diferenciada (varianza acotada, $|X| < 0,7$).

3. **Desplazamiento:** $v_t = w_t + 1$, para hacer la serie completamente positiva y poder aplicar modelos multiplicativos.

Puede que no hayamos conseguido la homocedasticidad total, ya que vemos cierta diferencia entre la varianza al principio de la serie en 1990 y al final con picos más pronunciados sobre el final de 2010 y 2014, sin embargo, hemos conseguido acotar mucho la apertura siendo $|X| < 0,7$ donde X representa la apertura respecto de la media de la serie. Luego, tenemos varianza acotada.

Reiteramos los pasos seguidos anteriormente para el entrenamiento de los distintos modelos. Realizadas las tres transformaciones, dividimos la serie transformada en train y test para comenzar con el entrenamiento de nuestro modelo.

3.4.2. Resultados sobre la serie transformada

Reentrenamos los cuatro modelos Holt-Winters sobre la serie transformada y obtenemos los resultados de los parámetros y las métricas AIC y BIC de bondad de ajuste:

Modelo	α	β	γ	AIC	BIC
(add, add)	0.0000	0.0000	0.1645	-1350.67	-1292.51
(add, mul)	0.0000	0.0000	0.1644	-1350.67	-1292.52
(mul, add)	0.0000	0.0000	0.1646	-1350.67	-1292.51
(mul, mul)	0.0000	0.0000	0.1644	-1350.67	-1292.52

Cuadro 3.3: Comparación de modelos Holt-Winters sobre la serie transformada.

De nuevo, como estas métricas no nos sirven para clasificar qué modelo es mejor para la predicción, vemos visualmente qué modelo se ajusta más a los valores del test y justificamos nuestra elección con otras métricas de bondad de ajuste, como el MAE o el RSME, en el conjunto de test. Lo que sí podemos destacar es que para todos los modelos hemos obtenido resultados muy similares, luego todos los modelos convergen hacia el mismo, obteniendo valores prácticamente idénticos en todas las métricas de ajuste:



Figura 3.6: Ajuste del modelo de Holt-Winters para la serie transformada.

Modelo	MAE	RMSE	MAPE (%)
(add, add)	0.11	0.19	23.65
(add, mul)	0.11	0.19	23.66
(mul, add)	0.11	0.19	23.65
(mul, mul)	0.11	0.19	23.66

Cuadro 3.4: Métricas sobre el test para la serie transformada.

Obtenemos prácticamente los mismos valores para todos los modelos (a falta de diferencias de milésimas a lo sumo), tanto en bondad de ajuste como en predicción. Esto indica que la transformación ha conseguido estabilizar la serie de manera que todos los modelos se comportan de forma similar.

Una vez elegido el modelo, es importante deshacer las transformaciones para recuperar la predicción en la escala original y que estas sean interpretables. Hay que recuperar estos datos de forma inversa a lo que se hizo en un primer momento: Deshacemos la traslación ($w_t = v_t - 1$), deshacemos la diferenciación, usando los últimos valores reales como ancla ($z_t = w_t + z_{t-1}$), y deshacemos el logaritmo y el desplazamiento: $y_t = e^{z_t} - 400$.




Figura 3.7: Predicción recuperada.

Finalmente vemos que ajusta mucho mejor y capta la tendencia, aproximándose mucho más a los valores reales. Luego, realizando estas transformaciones hemos conseguido un ajuste mucho mejor.

4 Modelo SARIMA

Tras el análisis anterior, hemos visto que la serie tiene tendencia y estacionalidad. Aparte de los modelos vistos anteriormente, existen modelos que ajustan estas características de forma correcta: los modelos ARIMA. En particular, existe una generalización de los modelos ARIMA centrado en el estudio de la estacionalidad: el modelo SARIMA. En este capítulo aplicamos la **metodología Box-Jenkins** para identificar, estimar y validar un modelo SARIMA(p, d, q)(P, D, Q)₁₂ para la serie de avistamientos de OVNI.

Primero de todo, debemos asegurarnos que se cumplen estas hipótesis y para ello, aplicaremos una serie de tests que confirmen la no estacionariedad de la serie. Para ello, usaremos el test de Ad-Fuller y el KPSS, obteniendo los siguientes resultados:

```
1 TEST ADF (H0: raíz unitaria ☐ no estacionaria)
2   Estadístico: -0.1197
3   p-valor:    0.9474
4   ☒ NO ESTACIONARIA (no rechaza H0)
5
6 TEST KPSS (H0: estacionaria)
7   Estadístico: 2.5235
8   p-valor:    0.0100
9   ☒ NO ESTACIONARIA (rechaza H0)
```

Por tanto, ambos tests nos confirman que la series no es estacionaria. Para confirmar nuestras hipótesis, podemos utilizar también las funciones de autocorrelación, tanto simple como parcial:




Figura 4.1: ACF y PACF de la serie original.

Como se aprecia un decrecimiento lento y cíclico, se pueden observar los patrones de estacionalidad y estacionariedad en la serie. Ante esto, no se satisfacen las condiciones ideales para el mdoelado de las series, luego aplicaremos la metodología Box-Jenkins para tratar de solucionar el problema:

4.1. Metodología Box-Jenkins

Para un correcto modelado de la serie, aplicamos la **metodología Box-Jenkins**, que establece un proceso sistemático de transformación e identificación del modelo SARIMA para ajustar correctamente a la serie real .

4.1.1. Homocedasticidad: transformación Box-Cox

El objetivo de esta metodología es conseguir que la serie sea homocedástica y estacionaria. Aplicando la metodología de Box-Jenkins, una vez que hemos visto que la serie no es estacionaria, debemos tratar la serie original mediante diferenciación y transformación para conseguir estos objetivos. El primer paso que se realiza es la transformación Box-Cox para restringir la varianza y que esta sea más fácil de modelar. Luego, como los gráficos muestran que **la varianza no es constante a lo largo del tiempo** (heterocedasticidad), aplicamos primero la **transformación Box-Cox** para estabilizarla:

$$y_t^{(\lambda)} = \begin{cases} \frac{y_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \ln(y_t) & \text{si } \lambda = 0 \end{cases} \quad (4.1)$$

donde λ se estima por máxima verosimilitud. El valor óptimo obtenido es $\hat{\lambda} = 0,4415$, próximo a 0,5, lo que equivale aproximadamente a una transformación de raíz cuadrada.

4.1.2. Estacionariedad en media: diferenciación

Los tests de estacionariedad y los correlogramas ACF/PACF confirman que **la serie no es estacionaria en media**. Para corregirlo, aplicamos diferenciación siguiendo el orden establecido por Box-Jenkins: Dado que la serie presenta estacionalidad con periodo $s = 12$, seguimos el orden establecido por la metodología y **diferenciamos primero estacionalmente** $\Delta_{12}z_t = z_t - z_{t-12}$:

1. **Si es estacionaria:** $D = 1$, $d = 0$. No es necesaria la diferenciación regular. Pasaríamos directamente a analizar los correlogramas para identificar p, q, P, Q .
2. **Si no es estacionaria:** Aplicamos adicionalmente la diferenciación regular ($d = 1$) y repetimos el proceso.

Tras esta primera diferenciación, estudiamos si hemos conseguido la serie estacionaria buscada, ya que en tal caso, podríamos continuar con la selección de parámetros. Volvemos a aplicar los contrastes:

```
1 TEST ADF (H0: raíz unitaria ☐ no estacionaria)
2   Estadístico: -3.4691
3   p-valor:    0.0088
4   ☒ ESTACIONARIA (rechaza H0)
5
6 TEST KPSS (H0: estacionaria)
7   Estadístico: 0.0837
8   p-valor:    0.1000
9   ☒ ESTACIONARIA (no rechaza H0)
```


Por tanto, con $D = 1$ y $d = 0$ la serie transformada es estacionaria, y podemos proceder a identificar los órdenes p, q, P, Q .

¿Por qué primero la diferenciación estacional? La estacionalidad es la fuente de no estacionariedad más dominante. Eliminándola primero, la serie resultante es más regular y el diagnóstico posterior es más limpio. Si se diferenciara en orden inverso, el patrón estacional persistiría y los correlogramas seguirían mostrando picos en los retardos múltiplos de m , dificultando la identificación del modelo.

Una vez aplicadas ambas transformaciones (primero Box-Cox para estabilizar la varianza, y luego la diferenciación estacional para eliminar la tendencia estacional) la serie es **estacionaria en media y homocedástica**.




Figura 4.2: Serie original, serie Box-Cox y serie Box-Cox diferenciada estacionalmente.

4.2. Identificación del modelo: ACF y PACF

A continuación, en la metodología de Box-Jenkins, se deben calcular los parámetros p, q, P, Q que definen el modelo SARIMA. Para la obtención de estos parámetros usaremos las funciones de autocorrelación

simple y parcial. Representamos las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie transformada para identificar los órdenes del modelo:




Figura 4.3: ACF y PACF de la serie diferenciada ($d = 0$, $D = 1$).

Del análisis de los correlogramas se extraen las siguientes conclusiones (Vemos dónde se cortan los lags para ver los significativos):

- **ACF**: corte significativo en retardo 3 $\Rightarrow$ MA(3); pico significativo en retardo 12 $\Rightarrow$ SMA(1)
- **PACF**: corte significativo en retardo 3 $\Rightarrow$ AR(3); corte en retardo 24 $\Rightarrow$ SMA(2)

Modelo candidato (bajo nuestro criterio): SARIMA (3, 0, 3)(2, 1, 1)₁₂. De todas formas, esta forma de seleccionar el modelo es una forma manual y subjetiva, por lo que hacemos todas las combinaciones de posibles candidatos y vemos cuál es el modelo que mejor ajusta (por el criterio del AIC):

4.3. Estimación y selección del modelo

Se realiza una búsqueda automática por rejilla sobre un espacio amplio de las posibles combinaciones candidatas (p, q, P, Q), seleccionando los modelos con menor AIC.

Order	Seasonal	AIC	BIC
(3, 0, 1)	(2, 1, 1, 12)	1143.88	1171.38
(3, 0, 2)	(2, 1, 1, 12)	1145.54	1176.48
(2, 0, 1)	(2, 1, 1, 12)	1146.37	1170.47
(3, 0, 3)	(2, 1, 1, 12)	1147.55	1181.93
(2, 0, 2)	(2, 1, 1, 12)	1148.04	1175.58
(1, 0, 1)	(2, 1, 1, 12)	1149.41	1170.10
(3, 0, 4)	(2, 1, 1, 12)	1149.85	1187.67
(2, 0, 3)	(2, 1, 1, 12)	1150.03	1181.01
(1, 0, 2)	(2, 1, 1, 12)	1151.06	1175.18
(2, 0, 4)	(2, 1, 1, 12)	1151.33	1185.76

Cuadro 4.1: Top modelos SARIMA por AIC tras la búsqueda por rejilla.

Una vez seleccionados los parámetros, pasamos al segundo paso de la metodología Box-Jenkins. Según la tabla de modelos posibles, el modelo con menor AIC es el SARIMA(3,0,1)(2,1,1)₁₂. Sin embargo, tras el entrenamiento, el análisis de su tabla `summary()` revela la existencia de varios parámetros que no son estadísticamente significativos. Pasamos al tercer paso de la metodología Box-Jenkins: **Validación**.

1	SARIMAX Results						
2	=====						
3	Dep. Variable:	avistamientos			No. Observations:	269	
4	Model:	SARIMAX(3, 0, 1)x(2, 1, 1, 12)			Log Likelihood	-563.938	
5	Sample:	01-01-1991			AIC	1143.876	
6		- 05-01-2013			BIC	1171.381	
7	=====						
8		coef	std err	z	P> z	[0.025	0.975]
9	-----						
10	ar.L1	0.9622	0.408	2.357	0.018	0.162	1.762
11	ar.L2	-0.0849	0.194	-0.437	0.662	-0.466	0.296
12	ar.L3	0.0120	0.147	0.082	0.935	-0.276	0.300
13	ma.L1	-0.5135	0.394	-1.302	0.193	-1.286	0.259
14	ar.S.L12	-0.6263	0.069	-9.044	0.000	-0.762	-0.491
15	ar.S.L24	-0.2847	0.083	-3.434	0.001	-0.447	-0.122
16	ma.S.L12	-1.0000	473.379	-0.002	0.998	-928.807	926.807
17	sigma2	6.7855	3212.247	0.002	0.998	-6289.102	6302.673
18	=====						
19	Ljung-Box (L1) (Q):	0.00			Jarque-Bera (JB):	6.62	
20	Prob(Q):	0.96			Prob(JB):	0.04	
21	Heteroskedasticity (H):	1.54			Skew:	-0.09	
22	Prob(H) (two-sided):	0.06			Kurtosis:	3.81	
23	=====						

Luego existen valores cuyo p-valor es superior a 0,05, lo que quiere decir que no existen evidencias significativas para rechazar la hipótesis nula (coeficiente nulo). Iremos reduciendo los órdenes hasta tener un modelo en el que todos los coeficientes sean estadísticamente significativos.

Debido a la restricción en la longitud de la entrega, este proceso de ajuste hasta la obtención del modelo con todos sus coeficientes estadísticamente significativos se saltará y se podrá ver en el código que se aporta como complemento a esta memoria. Finalmente, se obtienen cuatro modelos hasta llegar al óptimo, que aunque pierda un poco de explicabilidad en términos de AIC (coherente al eliminar variables), mejora en poder predictivo y explicabilidad del modelo. A continuación, se muestra la tabla resumen del modelo final:

1	SARIMAX Results						
2	=====						
3	Dep. Variable:	avistamientos			No. Observations:	269	
4	Model:	SARIMAX(1, 0, 1)x(2, 1, [], 12)			AIC	1236.791	
5	Sample:	01-01-1991			BIC	1254.025	
6		- 05-01-2013			HQIC	1243.741	
7	=====						
8		coef	std err	z	P> z	[0.025	0.975]
9	-----						
10	ar.L1	0.8463	0.051	16.520	0.000	0.746	0.947
11	ma.L1	-0.4170	0.084	-4.955	0.000	-0.582	-0.252
12	ar.S.L12	-0.9945	0.054	-18.275	0.000	-1.101	-0.888
13	ar.S.L24	-0.4729	0.057	-8.335	0.000	-0.584	-0.362
14	sigma2	11.5793	0.984	11.765	0.000	9.650	13.508
15	=====						
16	Ljung-Box (L1) (Q):	0.05			Jarque-Bera (JB):	1.55	
17	Prob(Q):	0.83			Prob(JB):	0.46	
18	Heteroskedasticity (H):	1.59			Skew:	-0.01	
19	Prob(H) (two-sided):	0.04			Kurtosis:	3.40	
20	=====						

También, estudiamos los residuos en el modelo ya que nos interesan que aquello que no perciba el modelo

sea lo más parecido al ruido blanco, es decir, un proceso estacionario, con varianza constante y que se distribuyan normalmente:




Figura 4.4: Residuos tras el modelo SARIMA.

Por tanto, los tests de diagnóstico confirman la idoneidad del modelo puesto que:

- **Ljung-Box**: $\text{Prob}(Q) = 0.83 \gg 0.05$, no se rechaza la hipótesis de ausencia de autocorrelación en los residuos $\Rightarrow$ los residuos son **ruido blanco**.
- **Jarque-Bera**: $\text{Prob}(JB) = 0.46 \gg 0.05$, no se rechaza la normalidad de los residuos.
- Todos los parámetros son **estadísticamente significativos** ($p\text{-valor} < 0,001$).

Visualmente, parece que el último modelo que hemos obtenido es el que mejor captura los patrones y la tendencia de la serie. Veámoslo numéricamente:

1	=====
2	COMPARACIÓN DE MODELOS SARIMA EN TEST
3	=====
4	Modelo MAE RMSE MAPE (%)
5	-----
6	SARIMA(3,0,1)x(2,1,1,12) 3.6405 5.4539 inf
7	SARIMA(2,0,1)x(2,1,1,12) 3.6359 5.4520 inf
8	SARIMA(2,0,1)x(2,1,0,12) 3.8579 6.0614 inf
9	SARIMA(1,0,1)x(2,1,0,12) 3.8559 6.0584 inf
10	=====
11	
12	📦 Mejor modelo por MAE: SARIMA(2,0,1)x(2,1,1,12)



Figura 4.5: Serie ajustada y predicción del modelo SARIMA(1,0,1)(2,1,0)₁₂ en escala transformada.

Sorprende ver que es el segundo modelo el que se ha seleccionado. Sin embargo, esto tiene una explicación y es porque la última observación desvirtúa la serie al ser una observación que está fuera del rango de la serie. Por ello, como el segundo modelo es el que más se acerca, esto compensa su falta de buena predicción en el resto de la serie. Si eliminamos esta última observación para comparar realmente entre los modelos, vemos cómo el último modelo construido es el mejor:

1	=====
2	COMPARACIÓN DE MODELOS SARIMA EN TEST
3	=====
4	Modelo MAE RMSE MAPE (%)
5	-----
6	SARIMA(3,0,1)x(2,1,1,12) 2.4982 2.9281 inf
7	SARIMA(2,0,1)x(2,1,1,12) 2.4923 2.9195 inf
8	SARIMA(2,0,1)x(2,1,0,12) 2.4701 2.6141 inf
9	SARIMA(1,0,1)x(2,1,0,12) 2.4697 2.6193 inf
10	=====
11	
12	➡ Mejor modelo por MAE: SARIMA(1,0,1)x(2,1,0,12)

Una vez hemos elegido el modelo que mejor ajusta la serie, tenemos que deshacer las transformaciones para tener una explicabilidad real. Procedemos con ello y vemos la representación de la estimación real:




Figura 4.6: Serie ajustada y predicción del modelo SARIMA(1,0,1)(2,1,0)₁₂.

Vemos que obtiene muchas mejores predicciones y captura todos los patrones con los picos en ciertas festividades. Procedemos con la expresión algebraica del modelo.

4.4. Expresión algebraica del modelo

El modelo SARIMA(p, d, q)(P, D, Q)₁₂ ajustado tiene la forma general:

$$\Phi_P(B^{12})\phi_p(B)(1-B)^d(1-B^{12})^D y_t = \Theta_Q(B^{12})\theta_q(B)\varepsilon_t \quad (4.2)$$

donde B es el operador de retardo ($B^k y_t = y_{t-k}$) y $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$.

Luego, los valores de los parámetros que forman parte del modelo vienen dados en la siguiente tabla:

Parámetros del modelo SARIMA

1	Parámetros estimados del modelo SARIMA:			
2	Parámetro	Estimación	IC 95% Inf	IC 95% Sup
3	-----			
4	ar.L1	0.8463	0.7459	0.9467
5	ma.L1	-0.4170	-0.5819	-0.2520
6	ar.S.L12	-0.9945	-1.1012	-0.8878
7	ar.S.L24	-0.4729	-0.5841	-0.3617
8	sigma2	11.5793	9.6503	13.5083

Ecuación completa con los parámetros sustituidos:

$$(1 + 0,9945 B^{12} + 0,4729 B^{24}) (1 - 0,8463 B) (1 - B^{12}) y_t = (1 - 0,4170 B) \varepsilon_t \quad (4.3)$$

donde $\varepsilon_t \sim \mathcal{N}(0, 11,5793)$.

4.5. Predicciones e intervalos de confianza

Se generan predicciones para los **12 meses siguientes** al último valor observado (junio 2014 – mayo 2015) con intervalos de confianza al 95 %. Se toman las predicciones en meses, ya que es la unidad del dataset. Para obtener menor granularidad, habría que agrupar por año.

Las predicciones se obtienen en la escala transformada (Box-Cox + diferenciación estacional) y luego se deshacen las transformaciones en orden inverso:




Figura 4.7: Predicción SARIMA para los 12 meses futuros con IC al 95 % (escala original).

Vemos cómo las predicciones siguen la tendencia de la serie, cumpliendo con el pico más alto en julio (verano), donde se producen el mayor número de avistamientos, para luego bajar, con algún repunte en épocas festivas.

De nuevo, para ver los valores numéricos de las predicciones acudir al código, donde se detallarán más profundamente debido a la restricción en la longitud de la entrega.

5 Conclusiones

A lo largo de esta memoria se ha realizado un análisis completo de la serie temporal de avistamientos de OVNI (1990–2014), aplicando la metodología de series temporales vista en clase. En este último capítulo conclusivo, haremos una comparación de los dos modelos obtenidos y veremos las conclusiones que se pueden obtener de ese análisis.

5.1. Comparación de modelos: Holt-Winters vs SARIMA

Se comparan las predicciones de ambos modelos sobre los 12 meses reservados (conjunto de test) tanto gráfica como numéricamente:




Figura 5.1: Comparación de predicciones sobre el conjunto test.

Visualmente, podemos observar que ambos modelos siguen muy de cerca y por ende, con poco error los valores reales del test. Una diferencia que se puede apreciar es que mayoritariamente, el modelo SARIMA sobrestima las observaciones mientras que el Holt-Winters las infraestima. En términos de error, no hay una gran desviación a pesar de esa última observación que rompe con la tendencia de la serie, por lo que ambos modelos fallan en su predicción, haciendo que este error aumente con respecto a la media del resto de observaciones. A continuación, mostramos una comparativa en tres métricas de error para comparar qué modelo ajusta mejor y es más adecuado para la predicción:




Figura 5.2: Comparación de métricas de error (MAE, RMSE, MAPE) entre Holt-Winters y SARIMA.

El modelo **Holt-Winters** **obtiene todas las métricas menores** que Holt-Winters, tanto el MAE, el RMSE y el MAPE, lo que indica que en promedio sus predicciones están más cerca de los valores reales. Destacar que la diferencia entre ambos modelos no es muy amplia, por lo que ambos tienen capacidades predictivas similares. Puede que el modelo SARIMA sea mejor para series en las que hay más volatilidad ya que capta mejor las fluctuaciones, mientras que el modelo Holt-Winters es más estable por lo que se deduce visualmente de las representaciones.

Finalmente, extraemos las conclusiones siguientes:

- La serie presenta una **tendencia creciente muy marcada** (especialmente desde el año 2000) y una **estacionalidad anual clara**, con picos en verano (julio-agosto) y en torno a festividades de fin de año. La **descomposición multiplicativa** es la más adecuada dado que la amplitud estacional crece con el nivel.
- Los modelos simples de suavizado exponencial (alisado simple y Holt) resultan **insuficientes**: el método de alisado simple no captura ni tendencia ni estacionalidad, y el método de Holt captura la tendencia pero no la estacionalidad.
- El modelo **Holt-Winters multiplicativo** ($\alpha = 0,2171$, $\beta = 0,0001$, $\gamma = 0,2818$) es el que mejor predice sobre el conjunto de test entre los modelos de suavizado exponencial, con $MAE = 123.92$ y $RMSE = 154.51$.
- El modelo **SARIMA(1,0,1)(2,1,0)₁₂** seleccionado mediante la metodología Box-Jenkins ofrece predicciones con intervalos de confianza formales y residuos que se comportan como ruido blanco (Ljung-Box: p-valor = 0.83; Jarque-Bera: p-valor = 0.46).
- La **comparación sobre el test** (últimos 12 meses) muestra que el modelo Holt-Winters obtiene un $MAE = 108.2$ y $RMSE = 143.5$, mejorando al SARIMA en términos de error absoluto. A pesar del aumento de la variabilidad en los últimos años, ambos modelos presentan buenos resultados para seguir el nivel absoluto de la serie, capturando tendencias y patrones.
- Ambos modelos coinciden en una **tendencia de crecimiento moderado** para los próximos 12 meses, con el patrón estacional habitual (pico en verano, mínimo en invierno). Aunque ambos presenten buenos resultados, optamos por el modelo de Holt-Winters para la predicción al presentar mejores resultados en las métricas de bondad de ajuste en el conjunto del test.